

Scenario Forge

Một câu tiếng Việt → một kịch bản OpenSCENARIO chạy được trên CARLA

Kỹ sư mô tả tình huống nguy hiểm bằng tiếng Việt. Hệ thống sinh file .xosc, người duyệt, CARLA chạy thật, rồi mới vào thư viện.

Xe tự lái không hỏng ở đường thẳng

Scenario Forge · P-130


- Nó hỏng ở tình huống hiếm: bị tắt đầu, xe ngược chiều, vượt đèn đỏ.
- Muốn thử những tình huống đó thì phải có kịch bản mô phỏng.
- Kịch bản là file XML hàng trăm dòng, viết tay, dễ sai hình học.



Hai đầu là hai kỹ năng khác nhau. Ở giữa là chỗ mọi thứ tắc.

Vào một câu. Ra một file chạy được.

Scenario Forge · P-130



Tải .xosc để chạy trên CARLA/ScenarioRunner — không cần viết XML thủ công.

Sáu tình huống đang sinh được

Scenario Forge · P-130



Tạt đầu
cut_in



Lệch làn
lane_drift



Phanh gấp
sudden_brake



Dừng giữa làn
stop_in_lane



Đi ngược chiều
wrong_way




Vượt đèn đỏ
run_red_light

Ảnh minh họa tình huống; kết quả chạy thật trong video demo.

Bên trong: 7 node, LLM chỉ làm 3

Scenario Forge · P-130



- LLM sinh nội dung có cấu trúc, không bao giờ sinh thẳng XML.
- Thứ tự node, nhánh lỗi và trần 3 vòng do code quyết định.
- Validator bắt hình học vô nghĩa trước khi tốn một giây GPU nào.

Không có gì tự vào thư viện

Scenario Forge · P-130




reject ở bất kỳ cổng nào đều phải kèm lý do — lý do được lưu lại

- Cổng 1 bảo vệ GPU: không duyệt thì không tiêu một giây máy nào.
- Cổng 2 bảo vệ dữ liệu: chỉ duyệt khi đã xem kết quả CARLA thật.
- Chỉ kịch bản qua cổng 2 mới được làm ví dụ cho lần sinh sau.

AI đề xuất. Người quyết định. Thư viện không tự bản.

Kiến trúc & tech stack

Scenario Forge · P-130



- Backend cloud không import carla — worker chỉ nhận chuỗi XML.
- Worker offline vẫn sinh/duyệt/tải file được; job nằm chờ trong hàng đợi.
- 533 test pass · 34 skip · CI test chặn mọi lần gọi LLM tính tiền.

Từ một kịch bản đến một chiến dịch đánh giá



Cặp A/B thật trên sc_011 — xe máy tạt đầu rồi phanh

	Baseline	BehaviorAgent
phanh	không phanh	phanh 0,5
giảm tốc sau đỉnh	—	3,676 m/s
va chạm	có · 10,823 s	có · 10,750 s

outcome = controller_collision → keep_regression

Mô hình lái đã phản ứng mà vẫn đâm — đúng thứ cần giữ làm ca hồi quy.

- Hai chốt thiết kế**
- Kết quả BehaviorAgent KHÔNG cập nhật VerificationLevel — không thì controller giỏi sẽ xoá chính bằng chứng làm baseline (ADR-021).
 - Lệnh vận tốc ego ở giây 2 quá 1 m/s là hệ thống bắt chạy lại.

Layer này nằm ngoài graph 7 node — không sửa node nào, chỉ thêm một lỗi vào theo lô và một phép so controller.

Nó chạy được tới đâu?

Scenario Forge · P-130



L4 là 60% — và em để nguyên con số đó trên slide.

“Chạy xong” không đồng nghĩa “đúng ý định”. L4 là mức duy nhất trả lời được câu đó, nên nó phải là mức khó nhất. Che nó đi thì ba mức trên cũng vô nghĩa.

Snapshot 29/08/2026, lấy trực tiếp từ database qua `/api/v1/metrics/quality`.

Đã phủ được bao nhiêu ODD?

Scenario Forge · P-130

	car				motorcycle				truck			
	clear	rain	h.rain	fog	clear	rain	h.rain	fog	clear	rain	h.rain	fog
cut_in	■	■	■	■	■	■	■	■	■	■	■	■
lane_drift	■	■	■	■	■	■	■	■	■	■	■	■
sudden_brake	■	■	■	■	■	■	■	■	■	■	■	■
stop_in_lane	■	■	■	■	■	■	■	■	■	■	■	■
wrong_way	■	■	■	■	■	■	■	■	■	■	■	■
run_red_light	■	■	■	■	■	■	■	■	■	■	■	■

72 / 72

ô đã có kịch bản sinh + validate
100% phạm vi converter

13 / 72

ô đã có lượt CARLA thật
phần còn lại chờ chạy


Phủ kín ô — chưa phủ kín lượt chạy.

Ô nhậ đã có kịch bản sinh và validate qua; ô đậm đã chạy thật trên CARLA. Phủ theo cặp trục cũng 74/74. Danh sách ô cần chạy tiếp đọc thẳng từ hình này.

Mỗi ô = một tổ hợp maneuver × loại xe × thời tiết trên anchor đã đo hình học.

Có thật sự được nguy hiểm không?

Scenario Forge · P-130

**60,00%**

17 va chạm + 4 suýt va chạm
= 21/35 lượt được nguy hiểm

Va chạm không phải thước đo duy nhất.

lane_drift chủ đích dựng near-miss — chấm nó bằng CollisionTest là chấm sai. Oracle đọc log quỹ đạo: heading, khe hở, lệch tim làn.

Máy chấm khớp người chấm: 10/13 = 76,92%

Phán quyết máy không gửi trước cho người chấm, để tránh mỗi câu trả lời.

3 bất đồng, để nguyên trên bàn:

- sc_018 — người đúng, máy sai
- sc_023 — người đúng, máy sai
- sc_024 — người sai, máy đúng

35 lượt chạy được, mỗi kịch bản chỉ tính lần chạy CARLA mới nhất.

3,510 s

latency p50 · toàn workflow 7 node

5,183 s

latency p95

\$0,002988

cost p50 / request

\$0,004135

cost p95 / request

\$0,064 cho cả 20 request

20/20 request hoàn tất, không request nào cần vòng sửa lại.

78,8% input token đọc từ cache


Prompt được tách ra và giữ ổn định để phần đầu vào lặp lại rơi vào cache — chi phí giảm khoảng hai phần ba.

- 16/20 câu được parser rule xử lý trọn — không tốn một lời gọi LLM nào.
- Không request nào phải leo thang lên model đắt hơn.
- Đây là snapshot một máy, một đường mạng — chưa phải load test.

20 request thật, chạy trên bản sao database thật, 29/08/2026.

Model rẻ hơn 73% — và em không đổi

Scenario Forge · P-130



Rẻ hơn 72,8% mỗi request. Nhưng p50 chậm hơn 42,8%, p95 chậm hơn 62,1%.

Tỉ lệ hoàn tất y hệt trên cùng tập đo. Rẻ hơn mà không sửa được failure mode đã biết, lại đánh đổi bằng độ trễ người dùng cảm nhận được — nên giữ gpt-5.4-mini làm primary, và ghi Luna lại như phương án dự phòng khi chi phí thành ràng buộc.

Cùng 20 mô tả, cùng snapshot database, cùng reasoning_effort.

Cắm controller của doanh nghiệp vào chỗ BehaviorAgent

Thêm một adapter ở worker là xong — backend không phải đụng tới. Câu hỏi đổi thành: kịch bản nào làm controller CỦA BẠN thất bại.

Chạy CARLA cho 59 ô đã có kịch bản

Ô đã kín, lượt chạy thì chưa: 13/72. Thứ tự đọc thẳng từ slide độ phủ — không cần họp để quyết chạy ô nào trước.

Mở rộng nhãn người trên từng maneuver

Hiện mới chấm tay 13 lượt, tập trung vào case lỗi đã biết. Càng nhiều nhãn thì con số 76,92% càng nói được nhiều.

Siết phân quyền ở backend

Enforce token/role cho review và WORKER_TOKEN, không chỉ phân vai trên frontend.

Live URL · Repo · Kiến trúc · Báo cáo đánh giá đầy đủ

[c4-app-t130.vercel.app](#) · [github.com/AI20K-Build-Phase-Cohort-3/P-130](#) · [ARCHITECTURE.md](#) · [eval/results/report.md](#)